

자원 제약형 에지 디바이스에서 CPU-GPU 추론의 처리량(Throughput) 특성 분석

이상우¹, 김세화¹, 권순홍¹, 김건우¹

¹한국외국어대학교 정보통신공학과

E-mail: tkddn0615@hufs.ac.kr

요 약

단일 프레임 병렬화 기반 CPU-GPU 추론 기법인 EdgeNN은 NVIDIA Jetson AGX Xavier · Orin 등 고성능 통합 에지 디바이스에서 지연 시간(Latency) 최적화를 목표로 제안되었다. 그러나 연속 프레임 스트림 응용에서는 처리량(Throughput)이 주요 지표이며, 자원이 제한적인 Jetson Xavier NX에서의 특성은 분석되지 않았다. 본 논문은 Xavier NX에서 EdgeNN을 처리량 관점에서 재평가하고 프레임 파이프라이닝을 적용하였다. 그 결과 AlexNet에서 처리량이 18.97→28.63 FPS(+50.9%), VGG-16에서 0.46→0.67 FPS(+45.7%)로 크게 향상된 반면, Residual 연결을 갖는 소형 CNN에서는 826.5→812.1 FPS(-1.7%)로 오히려 소폭 감소하였다. 이는 병목 스테이지 시간이 스테이지 시간의 합보다 충분히 작을수록 파이프라이닝 이득이 커지며, 병목 스테이지가 전체 실행 시간을 지배하는 모델에서는 프레임 파이프라이닝이 오히려 손해가 될 수 있음을 실증한다.

I. 서 론

CCTV 영상 분석, 자율주행 감지 등 연속 프레임 스트림 응용에서는 단일 프레임 지연 시간뿐 아니라 초당 처리 프레임 수, 즉 처리량이 핵심 성능 지표가 된다 [1]. CPU-GPU 통합 에지 디바이스를 위한 최근 SOTA 기법인 EdgeNN [2]은 한 프레임의 연산을 CPU와 GPU가 동시에 나누어 수행하는 단일 프레임 병렬화로 고성능 플랫폼에서 낮은 Latency를 달성하였다. 그러나 이 검증은 자원이 풍부한 플랫폼에서 단일 입력(Batch=1)의 프레임 지연 시간만을 지표로 수행된 것으로, 연속 입력 스트림의 처리량은 고려되지 않았다. 본 논문은 자원 제약형 소형 보드인 Jetson Xavier NX에서 EdgeNN을 처리량 관점에서 재평가하고, 프레임 파이프라이닝 적용에 따른 처리량 변화를 실험적으로 분석한다.

II. 배경 및 관련 연구

이기종 프로세서(CPU, GPU, NPU)를 병렬로 활용하는 DNN 추론 기법은 한 시점에 처리 중인 프레임의 수를 기준으로 두 부류로 나눌 수 있다. (1) 단일 프레임 병렬화(single-frame parallelism)는 한 프레임의 연산을 여러 프로세서가 동시에 나누어 수행하는 방식으로, 레이어의 연산을 출력 텐서 차원을 따라 분할(예: conv의 채널, FC의 뉴런 그룹)(intra-layer)하거나 DAG 상 독립 branch를 분산(inter-layer)하여 프레임당 지연

시간을 줄인다. (2) 프레임 파이프라이닝(frame-level pipelining)은 레이어들을 연속된 묶음인 스테이지(stage)로 분할해 프로세서에 할당하고 서로 다른 프레임들을 각 스테이지에서 동시에 실행하여 처리량을 높인다. 단일 프레임 병렬화의 대표 기법인 EdgeNN [2]은 intra-layer 분할과 inter-layer 분산을 결합하여 프레임당 지연 시간을 최소화하며, AGX Xavier · Orin에서 검증되었다. 프레임 파이프라이닝의 대표 기법인 CP-CNN [3]은 스테이지 단위 프레임 오버랩으로 처리량을 향상시키나 GPU-DLA 조합의 자율주행 응용을 대상으로 한다. 그러나 기존 연구들은 대부분 고성능 플랫폼과 GPU-DLA 조합을 대상으로 하며 [1], 자원 제약형 소형 보드에서 CPU-GPU 조합의 프레임 파이프라이닝 특성 분석은 미비하다. 본 논문은 이 공백을 실증적으로 채운다.

III. 실험 설계

대상 실행 방식 — Baseline은 EdgeNN [2]을 Xavier NX에서 최적으로 튜닝한 설정으로 실행한 것이다. EdgeNN은 CPU-GPU 간 부하 분할 비율을 조정할 수 있으나, Xavier NX에서는 CPU에 연산을 분담시키면 레이어마다 CPU-GPU 간 부분 결과 병합이 필요하고 이 과정에서 메모리 대역폭 경합으로 오히려 지연이 증가하여, 모든 레이어를 GPU가 처리하는 설정에서 처리량이 가장 높았다. 따라서 Baseline은 이 설정으로 한 프레임의 모든 레이어를 GPU가 순차 처리한다.

Pipeline 은 CP-CNN [3] 계열의 프레임 파이프라이닝으로, 처리량을 더 높이기 위해 유휴 CPU 자원을 활용한다. 구체적으로 모델을 세 스테이지(전처리(CPU), Conv 계열(GPU), FC(CPU))로 분할하고 서로 다른 프레임이 각 스테이지에서 동시 실행되도록 확장한다. 구현에서는 스테이지 간 동기화에 Linux futex, 데이터 전달에 다중 버퍼(6-slot), 스테이지별 CPU 코어 어피니티를 고정하였다.

플랫폼 — NVIDIA Jetson Xavier NX 의 메모리 대역폭은 59.7 GB/s 로, EdgeNN [2]이 검증한 AGX Xavier(137 GB/s)와 AGX Orin(204.8 GB/s) 대비 각각 44%, 29% 수준인 자원 제약형 소형 보드이다.

대상 모델 및 지표 — AlexNet, VGG-16, 그리고 Residual 연결을 갖는 소형 CNN 을 실측 대상으로 한다. 마지막 모델은 ResNet-18 등 표준 구성이 아닌, 3개의 합성곱 레이어와 residual branch, FC 레이어로 구성된 MNIST(28×28) 기반 소형 모델이다. 각각 3,000 프레임을 측정하고 초기 100 프레임은 warmup 으로 제외하였으며, 지표는 처리량(FPS)과 프레임 처리 시간(평균·p95)이다. 세 모델 모두 동일한 3-스테이지 분할과 측정 기준을 사용한다.

IV. 실험 결과




그림 1. 모델별 프레임 처리 시간

그림 1은 세 모델의 Baseline 과 Pipeline 프레임 처리 시간(막대: 평균, 위스커: p95)을 비교한다. AlexNet 에서 Baseline 은 52.57 ms(18.97 FPS), Pipeline 은 34.88 ms(28.63 FPS)로 처리량이 50.9% 향상되었고, p95 도 52.81 ms 에서 36.39 ms 로 감소하였다. AlexNet 은 병목 스테이지인 FC(CPU, 약 35 ms)가 스테이지 시간의 합(약 59 ms)보다 충분히 작아 프레임 오버랩 이득을 크게 얻을 수 있었다. VGG-16 에서도 Baseline 2175 ms(0.46 FPS)에서 Pipeline 1494 ms(0.67 FPS)로 처리량이 45.7% 향상되었다. 파이프라이닝 후 프레임 처리 간격은 병목 스테이지 시간(약 1494 ms)으로 수렴하는데, 이는 스테이지 시간의 합

(약 2173 ms)보다 충분히 작아 오버랩 이득을 얻을 수 있었다. 반면 Residual 연결을 갖는 소형 CNN 에서는 Baseline 1.21 ms(826.5 FPS)에서 Pipeline 1.23 ms(812.1 FPS)로 오히려 처리량이 소폭 감소하였다. 이는 모델이 매우 작아 GPU 스테이지가 약 1.2 ms, FC(CPU) 스테이지가 약 0.08 ms 로 병목 스테이지가 전체를 지배하여 프레임 오버랩 이득이 없는 반면, 스테이지 간 전달·동기화 오버헤드는 여전히 부담되기 때문이다. 즉 병목 스테이지 시간이 스테이지 시간의 합보다 충분히 작을수록 파이프라이닝 이득이 커지며, 병목이 전체를 지배하는 모델에서는 오히려 손해가 될 수 있음을 실증하였다.

파이프라이닝은 개별 프레임이 스테이지 간 전달 대기를 거치므로 프레임 단위 종단 지연은 증가하는 트레이드오프를 갖는다. 그러나 스트림 응용의 요구 지표는 초당 처리량이므로, Latency 중심 응용에는 EdgeNN [2]의 단일 프레임 병렬화가, Throughput 중심 응용에는 병목 스테이지 비중이 낮은 모델에 한하여 프레임 파이프라이닝이 적합하다.

V. 결론

본 논문은 Jetson Xavier NX 에서 EdgeNN [2]의 단일 프레임 병렬화를 처리량 관점에서 재평가하고 프레임 파이프라이닝을 적용하여, AlexNet 에서 18.97→28.63 FPS(+50.9%), VGG-16 에서 0.46→0.67 FPS(+45.7%)의 처리량 향상을 확인하였다. 반면 Residual 연결을 갖는 소형 CNN 에서는 826.5→812.1 FPS(-1.7%)로 소폭 감소하여, 파이프라이닝 이득이 병목 스테이지 시간과 스테이지 시간 합의 비율에 따라 달라지며 병목이 지배하는 모델에서는 손해가 될 수 있음을 실증하였다. 향후에는 다양한 DNN 모델로 실험을 확장하여 결과의 일반화 가능성을 검증할 예정이다.

참고문헌

- [1] A. A. Majeed et al., "Scheduling Techniques of AI Models on Modern Heterogeneous Edge GPU—A Critical Review," IEEE Trans. Ind. Informat., vol. 22, no. 4, pp. 2641-2657, Apr. 2026.
- [2] F. Zhang et al., "Breaking the Edge: Enabling Efficient Neural Network Inference on Integrated Edge Devices," IEEE Trans. Cloud Comput., vol. 13, no. 2, pp. 694-710, Apr.-Jun. 2025.
- [3] J.-M. Yang et al., "CP-CNN: Computational Parallelization of CNN-Based Object Detectors in Heterogeneous Embedded Systems for Autonomous Driving," IEEE Access, vol. 11, pp. 52812-52823, 2023.